

Tutoriais Inteligentes Baseados em Aprendizado por Reforço: Concepção, Implementação e Avaliação Empírica

Weber Martins¹, Ulisses R. Afonseca¹, Lauro E. G. Nalini², Viviane M. Gomes¹

¹Grupo PIRENEUS – Escola de Engenharia Elétrica e de Computação – Universidade Federal de Goiás (UFG) – Praça Universitária s/n – Setor Universitário
CEP 74605-220 – Goiânia – GO – Brazil

² Departamento de Computação/Psicologia – Universidade Católica de Goiás (UCG)
Av. Universitária 1440 – Setor Universitário – CEP 74605-010 – Goiânia – GO – Brazil
{weber,ulisses,viviane}@pireneus.eee.ufg.br, legn@ucg.br

Abstract. *In Intelligent Tutoring Systems (ITS), several techniques from Computational Intelligence have been employed to provide individualized tuition and higher knowledge gains. This article presents the development of a novel Hybrid Intelligent Tutoring System based on Reinforcement Learning's Softmax Algorithm: proposal, implementation and empirical evaluation. Reinforcement Learning is used to determine a dynamic course plan that takes into account the student's personal navigation history and his performance. Empirical experiments have compared the proposed system to free navigation (where students choose how to navigate on the course contents without any external guidance). Statistical analysis of collected data has shown promising results compared to other more complex hybrid ITS based on Multilayer Perceptrons.*

Resumo. *Em Sistemas Tutores Inteligentes (STI), várias técnicas de Inteligência Computacional têm sido empregadas para fornecer ensino individualizado e maiores ganhos de conhecimento ao aluno. Este artigo apresenta o desenvolvimento de um inédito Sistema Tutor Inteligente Híbrido baseado no Algoritmo Softmax de Aprendizado por Reforço: proposta, implementação e avaliação empírica. O Aprendizado por Reforço é usado para determinar um plano de curso dinâmico que considera a história de navegação pessoal do estudante e seu desempenho. Experimentos empíricos comparam o sistema proposto à navegação livre (onde o estudante escolhe como navegar no conteúdo do curso sem qualquer ajuda externa). A análise estatística dos dados coletados mostrou resultados promissores comparados a outros STI híbridos mais complexos, baseados em redes neurais perceptrons de multi-camadas.*

1. Introdução

Sistemas Tutores Inteligentes (STI) proporcionam ensino individualizado onde o aluno é um agente ativo no processo de aprendizagem. Em STI, cinco grandes áreas (Psicologia [Graig et al. 2007], Linguística, Inteligência Computacional [Russel and Norvig 1995], Neurociência, Antropologia e Filosofia) são naturalmente envolvidas com pesquisa e

desenvolvimento. A meta é criar modelos de ensino que considerem o conhecimento prévio do aluno, sua habilidade com o ambiente de ensino e suas capacidades/pré-disposições cognitivas.

Aprendizado por Reforço (RL, do Inglês, *Reinforcement Learning*) é uma técnica de aprendizado de máquina, bastante usada em controle de processos industriais, capaz de implementar o mecanismo de personalização do STI ao aprendiz. Em RL, um agente aprende por sucessivas interações com o seu ambiente e escolhe as ações que proporcionam os melhores resultados/ganhos. O ambiente apresenta, a cada interação, um novo estado (situação) e um valor numérico chamado reforço (*reward*) para avaliar a ação.

Para a utilização do RL em STI, o ambiente de aprendizado foi modelado de forma a representar as respostas dos alunos às questões, às possíveis opções de navegação e à estratégia pedagógica. O principal objetivo é demonstrar que a aplicação da técnica pode selecionar um plano de ensino específico para cada aluno de forma dinâmica, no sentido de contribuir para um desempenho satisfatório. O plano de ensino é uma seqüência de informações, como texto e imagens, que são apresentadas ao aprendiz de uma maneira que ele atinja a maior retenção de conhecimento possível. Outra meta secundária é a redução da quantidade de fragmentos de conteúdo necessária para o processo de aprendizagem.

2. Problema, Hipóteses e Variáveis

O problema pode ser sintetizado na questão: “Como implementar Sistemas Tutores Inteligentes?”. A hipótese principal deste trabalho argumenta que o uso de Aprendizado por Reforço é uma solução digna de ser submetida ao teste empírico. Como hipóteses secundárias, supomos que há redução do tamanho do conteúdo estudado e do tempo consumido do aluno quando comparados à navegação livre (sem controle externo). Portanto, a variável independente, que define grupos para posterior comparação, é a forma de controle (navegação guiada por RL ou livre); enquanto as variáveis dependentes, verdadeiros alvos de comparações, são o ganho normalizado de aprendizagem (retenção de conhecimento, o tamanho do conteúdo estudado (número de fragmentos observados pelo aluno) e o tempo consumido do aluno.

3. Fundamentação Teórica

3.1. Sistemas Tutores Inteligentes

As Tecnologias da Informação oferece inúmeras possibilidades à Educação. As aplicações educacionais desenvolvidas com tais tecnologias foram classificadas como aplicações de Instrução Assistida por Computador (IAC)¹², tendo sua origem na área educacional influenciada pela teoria comportamentalista de Skinner. Sua abordagem é

¹ A sigla CAI, do Inglês *Computer-Assisted Instruction*, é utilizada também. Estas ferramentas surgiram com base na Instrução Programada.

² Instrução Programada (IP) consiste em ensinar por pequenas lições onde cada uma deve ser aprendida para que o aluno possa avançar. Foi intensivamente estudada pelo psicólogo behaviorista B. F. Skinner.

centrada no professor do qual o aluno deve receber explicações expositivas para depois exercitá-las no computador.

Na década de 1970, teve início o uso de técnicas de Inteligência Artificial nos softwares de IAC dando origem aos softwares de Instrução Inteligente Assistida por Computador (ICAI³) ou Sistemas Tutores Inteligentes (STI) [Frigo et al. 2004]. Eles foram desenvolvidos em plataforma *stand alone* ou baseados em *web* [Prentzas and Hatzilygeroudis 2002]. Outro tipo é o Sistema Educacional Hipermissão Adaptativo⁴ desenvolvido especificamente para a *web* que adicionam a característica de apresentação e navegação inteligente. Estas categorias de *software* para Educação são chamadas de Sistemas Educacionais Inteligentes (ou IES do Inglês *Intelligent Educational Systems*), sendo o termo “Sistemas Tutores Inteligentes” mais difundido e utilizado neste trabalho. Segundo Prentzas em [Prentzas and Hatzilygeroudis 2002], e como representado na Figura 1, os principais componentes dos Sistemas Educacionais Inteligentes são:

- domínio do conhecimento: é o conteúdo a ser aprendido e pode ser constituído de texto, imagens, sons, exercícios, etc;
- modelo do usuário: é uma representação do aprendiz na qual podem ser utilizadas as características psicológicas, o perfil de aprendizagem, o conhecimento prévio do conteúdo, a diferença de seu conhecimento com o domínio de conhecimento do sistema, sua capacidade cognitiva e estado mental, seu histórico de navegação etc;
- modelo pedagógico: é constituído pela estratégia pedagógica escolhida;
- interface com usuário: um mecanismo para apresentar os diversos tipos de conteúdo ao usuário e de perceber suas interações com o sistema.




Figura 1. Estrutura de um STI

Dos novos STI surgidos nos últimos anos [Peres and Meira 2003] [Baldoni et al. 2004] [Bolzan and Giraffa 2002] [Guelpele et al. 2003] [Bennane 2002] [Cardoso et al. 2004] [Sykes and Franek 2004], destacamos o STI Híbrido desenvolvido por Melo e Meireles [Martins et al. 2004], onde questionários extensos sobre Perfil Psicológico (79

³ Intelligente Computer Assisted Instruction.

⁴ É usual a sigla AEHS do Inglês *Adaptive Educational Hypermedia Systems*.

questões) e Estilo de Aprendizagem (62 questões), respectivamente, foram empregados para realizar o treinamento prévio de redes perceptrons multi-camadas [Haykin 1998], responsáveis pela modelagem, por meio de distribuições probabilísticas, das preferências bem-sucedidas de cada tipo de aluno em relação aos níveis contextuais.

3.2. Aprendizado por Reforço

Aprendizado por Reforço é uma técnica de aprendizado de máquina onde um agente aprende por sucessivas interações em um ambiente dinâmico [Kaelbling et al. 1996]. Ele é responsável por selecionar possíveis ações para uma determinada situação apresentada pelo ambiente. O ambiente responde às ações e apresenta novas situações ao agente. A cada ação, é fornecida ao agente uma recompensa ou penalidade que indica o quanto o novo estado é desejado [Mitchell 1997].

Segundo Sutton & Barto [Sutton and Barto 1998], a definição de RL baseia-se no problema e, não, no método de aprendizado. São problemas onde o agente deve aprender a escolher as ações disponíveis, que alteram o estado do ambiente e utilizam uma função de recompensa para definir a qualidade da sequência de ações [Mitchell 1997]. Neste caso, o agente pode ou não ter um conhecimento prévio sobre o efeito de suas ações sobre o ambiente.

O agente está conectado ao ambiente via percepção e ação [Kaelbling et al. 1996]. O limite entre o ambiente e o agente é definido pelos limites de controle do agente. Tudo que o agente possui controle absoluto faz parte dele e o que ele não pode modificar arbitrariamente é considerado como parte do ambiente [Sutton and Barto 1998]. A definição completa do ambiente é chamada “tarefa” (*task*). Após cada escolha de ação, o ambiente fornece um sinal de retorno, chamado de reforço (ou recompensa), indicando a qualidade da ação escolhida (conforme representado na Figura 2). O agente aprende por suas próprias experiências ao interagir com o ambiente tentando atingir um objetivo. O estado do ambiente é um sinal com uma informação qualquer do ambiente como uma sensação imediata, uma versão processada desta sensação ou uma estrutura complexa. O agente deve descobrir quais ações têm maiores recompensas e seu objetivo é maximizar as recompensas em curto e longo prazo. Aprendizado por Reforço é aprender o que fazer: mapear situações às ações para maximizar o sinal de retorno.

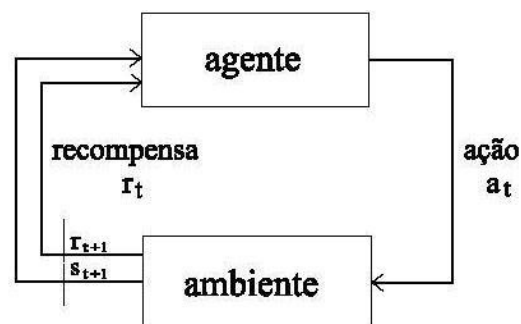


Figura 2. Interação entre agente e ambiente

A principal diferença entre o Aprendizado por Reforço e outras técnicas de aprendizado de máquina é a utilização da avaliação das ações tomadas [Sutton and Barto 1998]. Em outros métodos, são utilizados instruções ou exemplos, informando as

situações e as ações corretas que devem ser tomadas. O sistema pode, então, generalizar tais mapeamentos a situações não exemplificadas. No RL, o agente tenta descobrir, dentre as possíveis ações, quais delas promovem melhores resultados, utilizando apenas sua própria experiência. A Função de Recompensa define, para o estado atual, qual a melhor ação imediata enquanto a Função de Valor permite a avaliação das possíveis ações em longo prazo. Estas funções não são alteradas durante as interações enquanto são utilizadas para atualizar a Política, definindo os melhores mapeamentos estado-ação.

4. Sistema Proposto - Concepção e Implementação

Em linhas gerais, foi desenvolvido um ambiente modular de tutoria com duas formas de tutoria, inteligente e livre. O módulo de tutoria inteligente guia automaticamente o aluno utilizando uma técnica de aprendizado de máquina enquanto o módulo de tutoria livre permite que o aluno escolha como estudar. O módulo de tutoria livre foi desenvolvido para ser utilizado com referência para avaliar o desempenho do tutor inteligente.

4.1. Estratégia Pedagógica

O sistema proposto utiliza a mesma estratégia pedagógica implementada por Martins et al. [Martins et al. 2004]. O curso é composto por uma seqüência de contextos e cada contexto, de cinco níveis. Cada contexto é um pequeno trecho do curso, um fato, um procedimento, um princípio ou um conceito a ser aprendido. Os níveis são diferentes formas de apresentar o conteúdo do contexto: três formas de exposição com texto e figura (facilitado, intermediário e avançado) e dois níveis auxiliares (exemplos e perguntas freqüentes).

Quando o aluno inicia o curso ele é direcionado ao nível intermediário do primeiro contexto. A cada nível é apresentado um exercício para avaliar o aluno. Após responder ao exercício o aluno é, no módulo inteligente, guiado automaticamente para outro nível do mesmo contexto ou para o contexto seguinte. Se estiver utilizando o módulo livre, é apresentado ao aluno um menu para escolher qual o próximo nível ou avançar para o próximo contexto.

Algumas restrições de navegação são impostas em ambos os módulos tutores. Por exemplo, o aluno sempre inicia um contexto pelo nível intermediário. O aluno nunca pode retornar a contextos anteriores ou visitar um mesmo nível duas vezes. O esquema de navegação, utilizando esta estratégia pode ser visto na Figura 3 abaixo:




Figura 3. Estratégia de solução proposta

4.2. Material/Conteúdo Pedagógico

O conteúdo ensina “Introdução a Informática”, tendo sido gentilmente cedido por Melo e Meireles, [Melo et al. 2005] e [Meireles et al. 2005]. O conteúdo do curso foi composto com base em conhecimentos de Psicologia da Aprendizagem Humana. Em particular, empregou-se Instrução Programada, técnica bastante criticada, apesar de muito bem-sucedida [Skinner 1972], tendo sido defendida e avaliada por cientistas de Análise Experimental do Comportamento, um ramo da Psicologia que, ao contrário de outras áreas mais filosóficas, norteia-se por procedimentos operacionais e pelo emprego do método científico da forma utilizada nas Ciências Naturais (Física, Química e Biologia).

4.3. Modelo do Ambiente

É necessário criar um modelo do ambiente para ser utilizado junto à técnica de Aprendizado por Reforço. No sistema proposto, o modelo para o algoritmo representa a estratégia pedagógica. Os modelos mais simples podem considerar apenas as possíveis decisões e o acúmulo de recompensas. Nos mais complexos, podemos armazenar o histórico de todas as ações tomadas e considerar, para a tomada de decisão, todos possíveis caminhos e ganho acumulado para cada um deles até chegar ao último nível a ser visitado.

Dentre as modelagens realizadas, seguindo o princípio de iniciar pelas alternativas menos complexas, foi utilizada a alternativa mais simples, que representa apenas as possíveis opções (ações) para a navegação. O conjunto de ações que podem ser escolhidas é dinâmico: avançar para o próximo contexto é considerado somente após a visita de dois níveis e, ainda, um nível já visitado não é uma opção válida. O sistema inteligente tenta descobrir qual ação/destino pode produzir um maior reforço, isto é, fazer com que o aluno obtenha um melhor desempenho. Nesta modelagem, consideramos, como histórico de navegação, apenas o acúmulo de resultado das navegações anteriores.

4.4. Avaliação do Aluno

Antes da navegação no conteúdo do curso é aplicado um pré-teste com 15 questões, uma questão por contexto do curso. Após a navegação em todos os 15 contextos, o aluno passa por um teste final no mesmo formato do pré-teste. Ambos os questionários cobrem todo o conhecimento abordado no curso, focando principalmente no nível intermediário. Essas duas baterias de perguntas são utilizadas para avaliar o ganho normalizado da retenção de conhecimento do aluno após utilizar cada tutoria, livre e inteligente.

O ganho normalizado [Lakdawala et al. 2002] é uma medida que permite avaliar o quanto o aluno aprendeu em relação ao que ele ainda poderia aprender. A Equação 1 operacionaliza o cálculo do ganho normalizado. Assim, é possível comparar a retenção de conteúdo de alunos com diferentes níveis de conhecimento.

$$GN = \frac{NF - NI}{M - NI} * 100\% \quad (1)$$

Onde GN é o ganho normalizado, NF é a nota no teste final, NI é a nota no pré-teste e M é a nota máxima possível.

4.5. Técnica de Aprendizado por Reforço

A personalização do sistema ao aluno é realizada a partir da recompensa produzida pelas questões de cada nível. Trata-se de questões objetivas com quatro possíveis alternativas: correta, errada, parcialmente correta e a opção “não sei”. Cada tipo de resposta produz um reforço diferente. Este reforço é utilizado para individualizar o plano de ensino do aluno.

Deve-se ressaltar que o reforço produzido para o sistema tutor é diferente do produzido para o usuário. O reforço para o sistema constitui-se em um número, utilizado pelo algoritmo para guiar o aluno. O reforço para o aluno⁵ é uma mensagem produzida pelo sistema que aparece na tela, informando: “Parabéns! Resposta correta.”, “Esta não é a resposta mais correta.”, “Resposta incorreta.” e “Obrigado pela sinceridade.” para cada um dos tipos de alternativa descrito.

O algoritmo de aprendizado por reforço escolhido foi o *softmax* [Dayan and Hinton 1993]. Os critérios para tal escolha foram a adaptabilidade ao problema e a simplicidade. O *softmax* é um algoritmo simples que necessita apenas manter as informações das recompensas coletadas e as possíveis ações que podem ser tomadas. Ele atribui às ações uma probabilidade proporcional às suas estimativas de valor. A melhor ação continua tendo a maior probabilidade enquanto todas as outras são distribuídas em um *ranking* de acordo com suas estimativas de valor. O método mais comum para calcular a probabilidade é a distribuição de Gibbs ou Boltzmann que escolhe a ação a no tempo t com a probabilidade:

$$p(a, t) = \frac{e^{Q_t(a)/\tau}}{\sum_{b=1}^n e^{Q_t(b)/\tau}} \quad (2)$$

Onde τ é um parâmetro chamado “temperatura”, que torna as ações mais equiprováveis quando possui valores altos e grandes diferenças de probabilidade quanto possui valores pequenos (para as ações que possuem diferenças em suas estimativas de valores).

Para a escolha da temperatura foram realizadas simulações do ambiente de aprendizado considerando quatro situações: alunos que sempre acertam os exercícios, alunos que sempre escolhem a opção parcialmente correta, alunos que sempre erram e alunos que sempre respondem que não sabem. O valor 2 para a temperatura foi eleito por representar adequadamente as diferenças entre as probabilidades de escolha das ações apesar da pequena quantidade de reforços. Para o decaimento da temperatura também foram realizadas simulações. Como a quantidade de interações é pequena, o decaimento da temperatura afeta pouco as tomadas de decisões nesta implementação, tendo sido definido o valor de 3%

⁵ Reforço é um termo da Psicologia Comportamental, utilizado na técnica de contingência de reforço que é considerado um controle eficaz do comportamento [Skinner 1972].

5. Avaliação Empírica e Resultados

No total, 124 alunos foram submetidos às navegações livre e inteligente. Destes, 26 não concluíram todas as etapas do curso, nove concluíram e apresentaram erro durante a coleta e 89 concluíram corretamente.

O ganho normalizado obtido em [Melo et al. 2005] e [Meireles et al. 2005] é, respectivamente, 9,32% e 9,78% superiores ao ganho do sistema proposto neste trabalho. Porém, a diferença entre ganhos normalizados do STI e do STL foi bem maior no sistema proposto, respectivamente, 62,92% e 62,03%.

Conforme pode ser observado na Tabela 1, no sistema proposto, as notas iniciais no STI e no STL estão muito próximas, respaldando a suposição de que os grupos que realizaram STI e STL estavam, antes da experiência de tutoria, em nível de conhecimento semelhante. Para confirmar tal suposição, o teste t-Student foi escolhido, resultando no valor observado (calculado) de -0,49, claramente não significativo pois, com nível de significância de 5%, a zona crítica bicaudal tem valores significativos inferiores a -1,68 e superiores a +1,68. Uma vez constatada a semelhança entre os dois grupos, podemos aplicar testes inferenciais para determinar se, após a tutoria, houve diferenças significativas.

Quanto ao ganho normalizado, a estatística t apontou um valor observado significativo de 2,85, tendo em vista que a zona crítica unilateral à direita inicia em 1,68 (considerando nível de significância de 5%). Assim, podemos inferir que o sistema proposto realmente causou a diferença, pois atua não apenas na amostra coletada, mas em toda a população. Tal fato fortalece a hipótese básica inicial, que conjecturou um melhor desempenho dos alunos guiados inteligentemente (com Aprendizado por Reforço).

Tabela 1. Análise descritiva dos dados

| Grandeza | Situação | Média | Desvio |
|-------------------|----------|-------|--------|
| Nota Inicial | STI | 5,65 | 1,32 |
| | STL | 5,83 | 1,43 |
| Nota Final | STI | 8,04 | 1,43 |
| | STL | 7,01 | 1,65 |
| Ganho Normalizado | STI | 52,61 | 34,16 |
| | STL | 23,32 | 41,63 |

Quanto ao tamanho do conteúdo estudado pelo aluno, baseando-se no número de contextos visitados e, novamente, no emprego do teste t-Student, o valor obtido de t observado igual a -20,19 é claramente significativo, pois a zona crítica unilateral esquerda inicia em -1,74 quando o nível de significância de 5% é usado. Entretanto, quando ao tempo consumido do aluno, descontados os tempos empregados nas avaliações iniciais e finais, a hipótese nula (que supõe não existirem diferenças significativas) não pode ser rejeitada uma vez que o valor observado da estatística t (-0,69) ficou fora da zona crítica (cujo início era -1,68). Assim, das hipóteses secundárias, apenas a hipótese de menos conteúdo estudado foi corroborada, sugerindo que o aluno gastou mais tempo em cada nível.

6. Conclusão

O presente trabalho apresentou o desenvolvimento (concepção, implementação e avaliação empírica) de um inédito Sistema Tutor Inteligente baseado em Aprendizado por Reforço. Quando comparado a modelos baseados em longos treinamentos de redes multilayer perceptrons e estruturados sobre complexas teorias de Perfil Psicológico (Psicologia da Personalidade) [Melo et al. 2005] e Estilo de Aprendizagem (Educação) [Meireles et al. 2005], o sistema proposto apresentou desempenho equivalente quanto ao ganho normalizado, mesmo sem recorrer aos longos questionários iniciais para levantar características pessoais, superando-os quando se analisou a diferença entre ganhos do sistema proposto e da navegação livre.

No sistema proposto, o aluno, além de navegar por conteúdos de modo individualizado e sensível ao seu desempenho, foi exposto a significativamente menos contextos, consumindo tempos semelhantes. Assim, podemos inferir que a adaptação ao aluno atraiu mais sua atenção, conduzindo-o ao melhor rendimento (mostrado pelo ganho normalizado).

A viabilidade da aplicação de técnicas de Aprendizado por Reforço foi, portanto, comprovada com este trabalho. Trabalhos futuros pretendem avaliar o efeito do sistema desenvolvido em cursos mais longos, não somente em uma única sessão. Podemos ainda substituir o modelo da estratégia pedagógica por uma versão mais informativa ou ainda utilizar outras estratégias pedagógicas. Com outros modelos ou estratégias, é possível também avaliar a aplicação de outras técnicas de RL, reutilizando toda a estrutura modular do sistema.

7. Referências

- Baldoni, M., Baroglio, C. and Patti, V. (2004). Web-Based Adaptive Tutoring: An Approach Based on Logic Agents and Reasoning about Actions, Università degli Studi di Torino, Itália.
- Bennane, A. (2002). An approach of reinforcement learning use in tutoring systems, Lecture Notes in Computer Science 2363/2002: 775-782.
- Bolzan, W. and Giraffa, L. M. M. (2002). Estudo comparativo sobre Sistemas Tutores Inteligentes Multiagentes, Technical Report Series, Number 024. Faculdade de Informática, PUCRS, Brasil.
- Cardoso, J., Postal, A., Pozzebon, E., Frigo, L. B. and Bittencourt, G. (2004). MATHTUTOR: A Multi-Agent Intelligent Tutoring System, IAIA-IFIP 2004 International Conference on Artificial Intelligence Applications and Innovations, IFIP World Computer Congress, Toulouse - França..
- Dayan, P. and Hinton, G. (1993). Feudal reinforcement learning, Advances in Neural Information Processing Systems 5: 71-278.
- Frigo, L. B., Pozzebon, E. and Bittencourt, G. (2004). O Papel dos Agentes Inteligentes nos Sistemas Tutores Inteligentes, World Congress on Engineering and Technology Education, São Paulo, Brasil.

- Graig, S. D., Hu, X., Gholson, B., Marks, W. and Graesser, A. C. (2007). The Tutoring Research Group. Department of Psychology, The University of Memphis, TN 38152, EUA, Disponível em <http://psyc.memphis.edu/trg/trg.htm>.
- Guelpeli, M. V. C., Ribeiro, C. H. C. and Omar, N. (2003). Utilização de Aprendizado por Reforço para Modelagem Autônoma de Aprendiz em um Tutor Inteligente, XIV Simpósio Brasileiro de Informática na Educação - UFRJ, Brasil.
- Haykin, S. (1998). Neural Networks: A Comprehensive Foundation, Prentice Hall PTR, Upper Saddle River, NJ, EUA.
- Kaelbling, L. P., Littman, M. L. and A, W. M. (1996). Reinforcement Learning: A Survey, Journal of Artificial Intelligence Research.
- Lakdawala, V. K., Zahorian, S. A., González, O. R., Kumar, H. A. and Jr, J. F. L. (2002). An instrument for assessing knowledge gain in a first course in circuit theory, Department of Electrical and Computer Engineering. Old Dominion University, EUA.
- Martins, W., Melo, F. R., Meireles, V. and Nalini, L. E. G. (2004). A novel hybrid intelligent tutoring system and its use of psychological profiles and learning styles, Lecture Notes on Computer Science 3220: 830-832.
- Meireles, V., Martins, W., Melo, F. R. and Nalini, L. E. G. (2005). Análise de funcionalidade da rede neural artificial em sistemas tutores inteligentes baseados em estilos de aprendizagem, Anais do VII Congresso Brasileiro de Redes Neurais, Natal, RN, Brasil pp. 452-457.
- Melo, F. R., Martins, W., Meireles, V. and Nalini, L. E. G. (2005). Rede neural artificial em sistemas tutores inteligentes híbridos baseados em tipologia psicológica – implementação e análise empírica, Anais do VII Congresso Brasileiro de Redes Neurais, Natal, RN, Brasil pp. 411-416.
- Mitchell, T. M. (1997). Machine Learning, McGraw-Hill, EUA.
- Peres, F. and Meira, L. (2003). Avaliação de software educacional centrado no diálogo: interface, colaboração e conceitos científicos, Universidade Federal de Pernambuco, Departamento de Psicologia, Brasil.
- Prentzas, J. and Hatzilygeroudis, I. (2002). Intelligent educational systems for individualized learning, Workshop on Computer Science and Information Technologies CSIT2002, Patras, Grécia .
- Russell, S. J. and Norvig, P. (1995). Artificial intelligence: a modern approach, Prentice-Hall, Inc., Upper Saddle River, NJ, EUA.
- Skinner, B. F. (1972). Tecnologia do ensino, Editora da Universidade de São Paulo. São Paulo, Brasil.
- Sutton, R. S. and Barto, A. G. (1998). Reinforcement learning: an introduction, MIT Press, Cambridge, Massachusetts, EUA.
- Sykes, E. R. and Franek, F. (2004). A Prototype for an Intelligent Tutoring System for Students Learning to Program in Java, IEEE International Conference on Advanced Learning Technologies, Joensuu, Finlândia.